بسم الله الرحمن الرحیم

گزارش کار فاز دوم قسمت دوم

محیط های ناشناخته

استاد مربوطه: استاد حسین کارشناس

دستیار آموزشی: پوریا صامتی

اعضای تیم

یونس ایوبی راد ۴۰۱۳۶۱۳۰۱۱

پویا اسفندانی ۴۰۱۳۶۱۳۰۰۵

کلاس شبکه عصبی

در این کلاس در گام اول یک کلاس شبکه عصبی تعریف شده.

```
class QNetwork(nn.Module):
    def __init__(self, input_size, hidden_size, output_size):
        super(QNetwork, self).__init__()
        self.FC = nn.Sequential(
            nn.Linear(input_size, hidden_size),
            nn.ReLU(),
            nn.Linear(hidden_size, hidden_size),
            nn.ReLU(),
            nn.Linear(hidden_size, output_size)
        )
        self.init_weights()

    def init_weights(self):
        for layer in self.FC:
            if isinstance(layer, nn.Linear):
                nn.init.kaiming_uniform_(layer.weight, nonlinearity='relu')

    def forward(self, x):
        return self.FC(x)
```

این کد یک شبکه عصبی (Fully Connected Feedforward Neural Network)است که برای پیش‌بینی مقدار Q در تقویت یادگیری طراحی شده است. شبکه سه لایه دارد: ورودی، مخفی، و خروجی. لایه‌ها شامل توابع ریاضی هستند که داده‌ها را پردازش می‌کنند تا الگوهای پیچیده یاد گرفته شوند. از ReLU برای غیرخطی کردن مدل و از مقداردهی اولیه مناسب برای وزن‌ها استفاده شده تا یادگیری بهتر انجام شود. این مدل وضعیت محیط را می‌گیرد و برای هر اقدام ممکن یک مقدار Q پیش‌بینی می‌کند، که نشان می‌دهد هر اقدام چقدر پاداش دارد. هدف آن انتخاب بهترین اقدام در هر وضعیت است و کاربرد آن بیشتر در بازی‌ها و تصمیم‌گیری‌های هوشمند است.

در ابتدای کار، شبکه هیچ چیز نمی‌داند، و وزن‌ها (ارتباط بین نودها) به‌طور تصادفی تنظیم می‌شوند. روش "کایمینگ یونیفرم" که در اینجا استفاده شده، یک روش خاص برای مقداردهی وزن‌ها است تا مطمئن شویم یادگیری شبکه سریع‌تر و پایدارتر خواهد بود.

کلاس حافظه

```
. class ReplayBuffer:
    def __init__(self, length):
        self.memory = deque(maxlen=length)

    def add(self, member):
        self.memory.append((
            torch.tensor(member[0], dtype=torch.float32),
            torch.tensor(member[1], dtype=torch.long),
            torch.tensor(member[2], dtype=torch.long),
            torch.tensor(member[3], dtype=torch.float32),
            torch.tensor(member[4], dtype=torch.bool)
        ))

    def sample(self, batch_size):
        batch = random.sample(self.memory, batch_size)
        states, actions, rewards, next_states, dones = zip(*batch)
        return (
            torch.stack(states).to(device),
            torch.stack(actions).to(device),
            torch.stack(rewards).to(device),
            torch.stack(next_states).to(device),
            torch.stack(dones).to(device)
        )

    def __len__(self):
        return len(self.memory)
```

کلاس **ReplayBuffer** یک حافظه برای ذخیره و نمونه‌گیری تجربیات در یادگیری تقویتی است. تجربیات شامل وضعیت فعلی، اقدام، پاداش، وضعیت بعدی، و علامت پایان اپیزود هستند. این داده‌ها به‌صورت تانسور ذخیره می‌شوند و هنگام آموزش مدل، به‌صورت تصادفی نمونه‌گیری می‌شوند. این فرآیند از همبستگی داده‌های متوالی جلوگیری کرده و یادگیری را پایدارتر می‌کند. همچنین، وقتی حافظه پر شود، تجربیات قدیمی حذف می‌شوند تا جا برای داده‌های جدید باز شود. هدف اصلی، بهبود آموزش مدل از تجربیات گذشته است.

کلاس Agent

کلاس Agent نماینده‌ی عامل هوشمندی است که در محیط یادگیری تقویتی عمل می‌کند. عامل با استفاده از شبکه‌های عصبی تصمیم می‌گیرد و خودش را آموزش می‌دهد تا پاداش بیشتری در محیط کسب کند

سازنده:

عامل شامل دو شبکه عصبی است:

Policy Network : برای انتخاب اقدامات.

Target Network: برای پیش‌بینی پاداش‌های آینده، که هر از گاهی به‌روزرسانی می‌شود.

از الگوریتم Adamبرای بهینه‌سازی وزن‌های شبکه و از huber lossبرای محاسبه خطا (loss) استفاده می‌کند.
حافظه‌ای از نوع ReplayBufferبرای ذخیره تجربیات دارد.
پارامترهای یادگیری تقویتی:

Epsilon: احتمال انتخاب اقدام تصادفی (برای کاوش).

Gamma: ضریب تخفیف برای ارزش پاداش‌های آینده.

epsilon_decay: نرخ کاهش مقدار epsilon با گذر زمان.

```
def __init__(self, input_size, hidden_size, output_size):
    self.n_games = 0
    self.epsilon = epsilon
    self.epsilon_min = epsilon_min
    self.epsilon_decay = epsilon_decay
    self.gamma = gamma
    self.memory = ReplayBuffer(memory_size)
    self.policy = QNetwork(input_size, hidden_size, output_size).to(device)
    self.target = QNetwork(input_size, hidden_size, output_size).to(device)
    self.target.load_state_dict(self.policy.state_dict())
    self.optimizer = optim.Adam(self.policy.parameters(), lr=learning_rate)
    self.loss_fn = nn.SmoothL1Loss(beta=1.0)
    self.loss_history = []
```

تابع انتخاب:

تابع select_actionاقدام عامل را با استفاده از استراتژی ε-greedyانتخاب می‌کند:
اگر مقدار تصادفی از epsilonکمتر باشد، اقدام تصادفی برای کاوش (Exploration) انتخاب می‌شود.
در غیر این صورت، اقدام بهینه بر اساس شبکه عصبی Policy پیشبینی میشود.
وضعیت ورودی (state) به Tensor تبدیل و محاسبه به GPU ارسال می‌شود.
شبکه Q-Value هر اقدام را محاسبه کرده و اقدام با بیشترین مقدار انتخاب می‌شود.

تابع Train :

این تابع عامل را با استفاده از داده‌های ذخیره‌شده در حافظه آموزش می‌دهد. مراحل به شرح زیر است:

بررسی شرط آموزش:
اگر داده‌های حافظه کمتر از اندازه مینی‌باتچ باشد، تابع متوقف می‌شود.

نمونه‌گیری از حافظه:
تجربیات ذخیره‌شده (شامل وضعیت‌ها، اقدامات، پاداش‌ها، وضعیت‌های بعدی، و وضعیت پایان) به‌صورت تصادفی نمونه‌گیری می‌شوند.

محاسبه مقادیر Q فعلی:
شبکه **Policy** مقادیر Q را برای وضعیت‌های فعلی پیش‌بینی می‌کند. سپس با استفاده از اقدامات انجام‌شده، مقادیر مرتبط انتخاب می‌شوند.

محاسبه مقادیر Q هدف:(Target Q)

با استفاده از **Target Network**، بیشترین مقدار Q برای وضعیت‌های بعدی پیش‌بینی می‌شود.

محاسبه و به‌روزرسانی خطا:(Loss)
خطای بین مقادیر Q فعلی و مقادیر Q هدف با استفاده از تابع از دست دادن **(loss function)** محاسبه می‌شود. سپس، وزن‌های شبکه **Policy** با استفاده از گرادیان نزولی به‌روزرسانی می‌شوند.

به‌روزرسانی:(Epsilon) ε
مقدار ε کاهش می‌یابد تا عامل به‌تدریج بیشتر بهره‌برداری کرده و کمتر کاوش کند.

تابع های کلاس مین:

```
def choose_step(env, agent, state,previous_pigs):
    pushState = np.append(np.array(state),np.array(previous_pigs))
    action = agent.select_action(pushState)
    next_state, reward,pigs, done = env.step(action)
    temp = reward
    if state == next_state:
        temp = -10
    if done:
        agent.n_games = agent.n_games + 1
        if agent.n_games % 10 == 0:
            agent.target.load_state_dict(agent.policy.state_dict())
        agent.epsilon = agent.epsilon * agent.epsilon_decay
    pushNextState = np.append(np.array(next_state),np.array(pigs))
    agent.memory.add([pushState, action, temp, pushNextState, done])
    return pigs, next_state, action, reward, done
```

این تابع ۵ ورودی دارد محیط، عامل‌هوشمند، استیت کنونی، لیست خوک های سابق که در قسمت پوش استیت لیست خوک ها را با استیت کنونی append می‌کند و پوش استیت جدیدی به وجودی میاورد سپس از تابع select action از ایجنت را فرا میخواند و استیت را می‌خواند، سپس کار را در محیط انجام می‌دهد و استیت جدید و خوک ها و پاداش و نتیجه بازی را میگیرید و بعد از آن جایزه را در تمپ میریزم و اگراستیت کنونی برابر با استیت قبلی بود تمپ را به منفی ده تبدیل میکنم(برای جلوگیری از رفتن مکرر به دیوار) و اگر بازی اتمام یافته بود تعداد بازی های ایجنت یک عدد اضافه میشود و اپسیلون اپدیت میشود و اگر مود تعداد بازی ها به ده برابر با صفر بود درخت پالیسی را در درخت تارگت کپی میکند و سپس پوش استیت بعدی و خوک های آینده را در یک آرایه نامپای قرار میدهد و آن ها را به حافظه ایجنت اضافه میکند و خوک ها، استیت بعدی، کار انجام شده، جایزه و نتیجه بازی را بر میگرداند.

تابع مین:

```
if __name__ == "__main__":
    device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

    env = UnknownAngryBirds()
    screen, clock = PygameInit.initialization()
    episode_reward = []
    agent = Agent(10,128,4)
    for episode in range(1000):
        screen, clock = PygameInit.initialization()
        state = env.reset()
        visited_node = []
        running = True
        total_reward = 0
        pigs = [1,1,1,1,1,1,1,1]
        while running:
            for event in pygame.event.get():
                if event.type == pygame.QUIT:
                    pygame.quit()
                env.render(screen)
            pigs, next_state, action, reward, done = choose_step(env, agent,
state,pigs)
            visited_node = list
            state = next_state
            total_reward += reward
            if len(agent.memory) > 256:
                agent.train()

            if done:
                print(f"Episode {episode} finished with reward:
{total_reward}")
                episode_reward.append(total_reward)
                running = False
```

چندین نمونه کار از کد:

مثال ۱

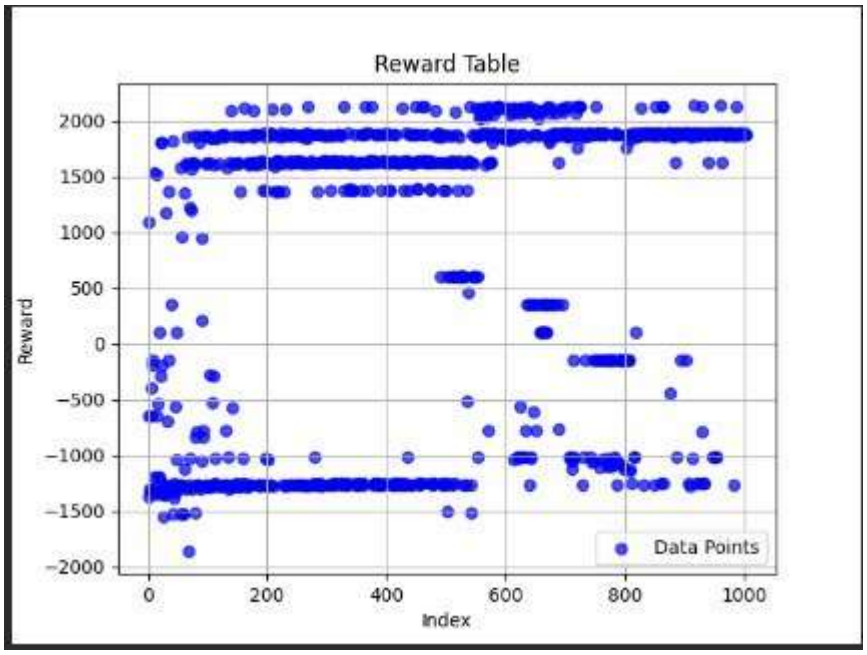


```
Episode 0 finished with reward: 1887
Episode 1 finished with reward: 1886
Episode 2 finished with reward: 1884
Episode 3 finished with reward: 1884
Episode 4 finished with reward: 1886
```

تست دوم

(در اینجا در کنار پرنده آبی TNT قرار داشت و احتمال برخورد به آن بود)

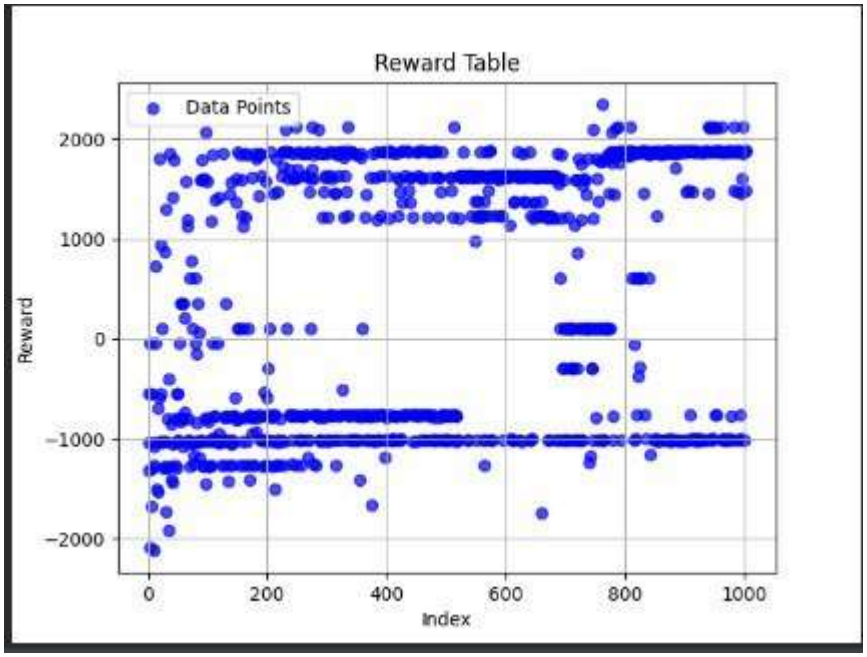

تست سوم

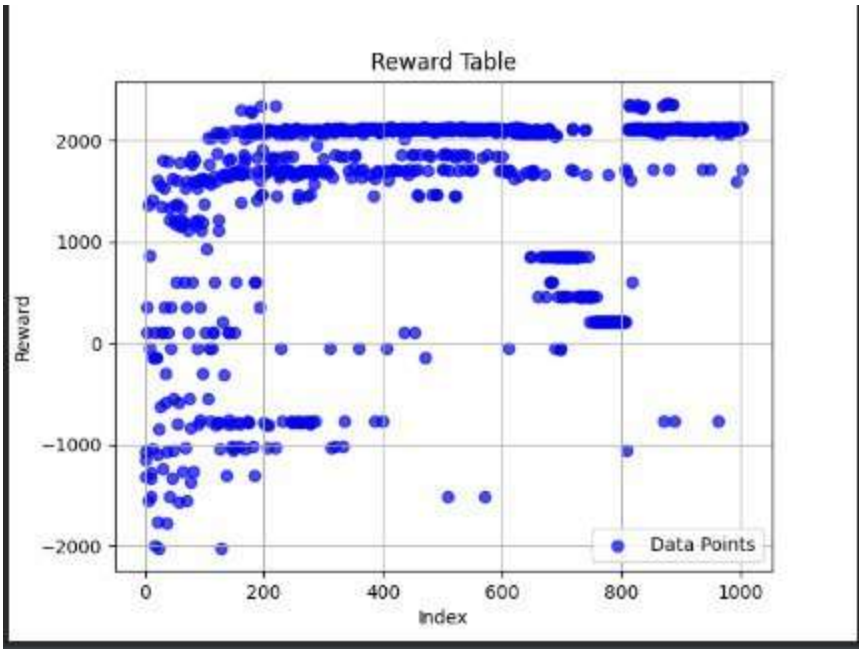


```
Episode 0 finished with reward: 2125
Episode 1 finished with reward: 2121
Episode 2 finished with reward: 2129
Episode 3 finished with reward: 2121
Episode 4 finished with reward: 1719
```

تست چهارم

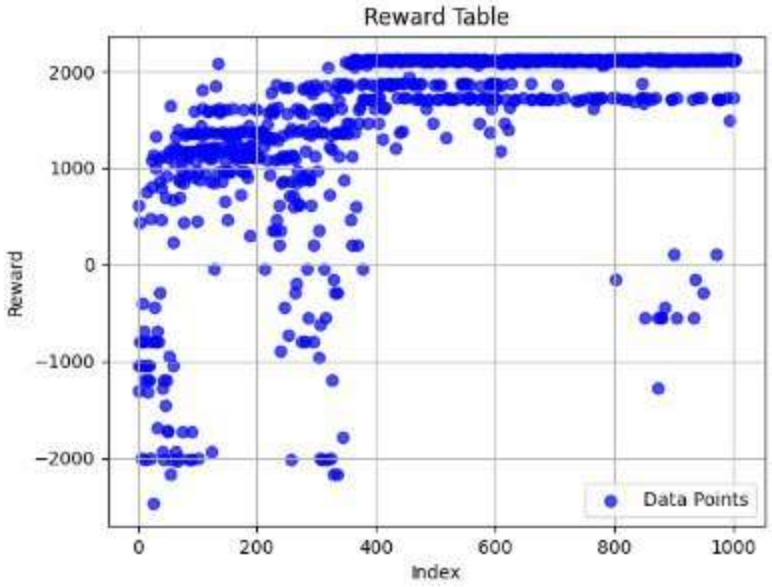


```
Episode 0 finished with reward: 1726
Episode 1 finished with reward: 2113
Episode 2 finished with reward: 2125
Episode 3 finished with reward: 2122
Episode 4 finished with reward: 2118
```

همراه با فیلم

تست پنجم

TNT در ایندکس [1,1] بود

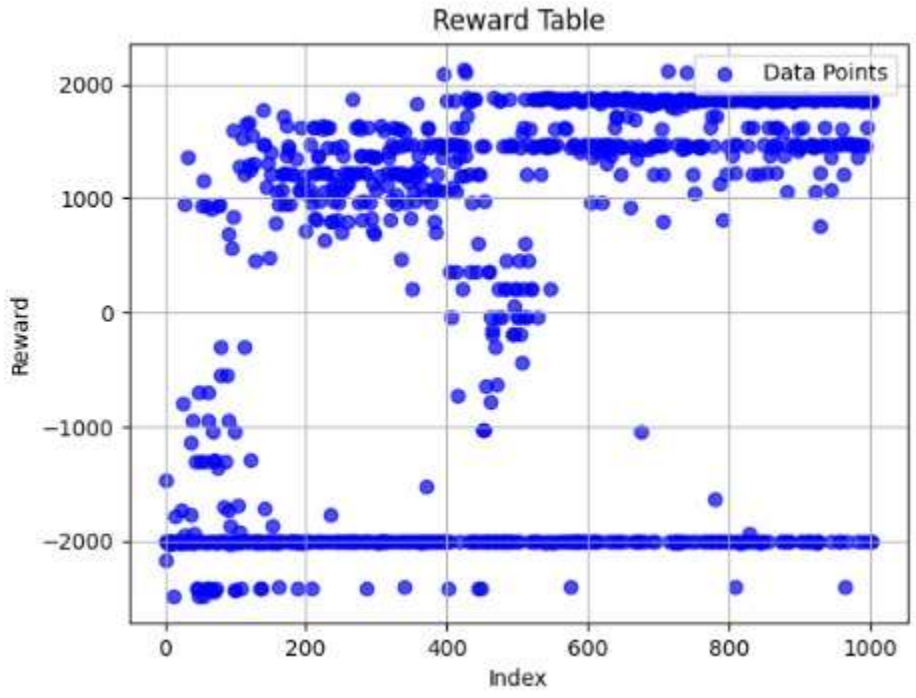

همراه با فیلم

مثال ششم

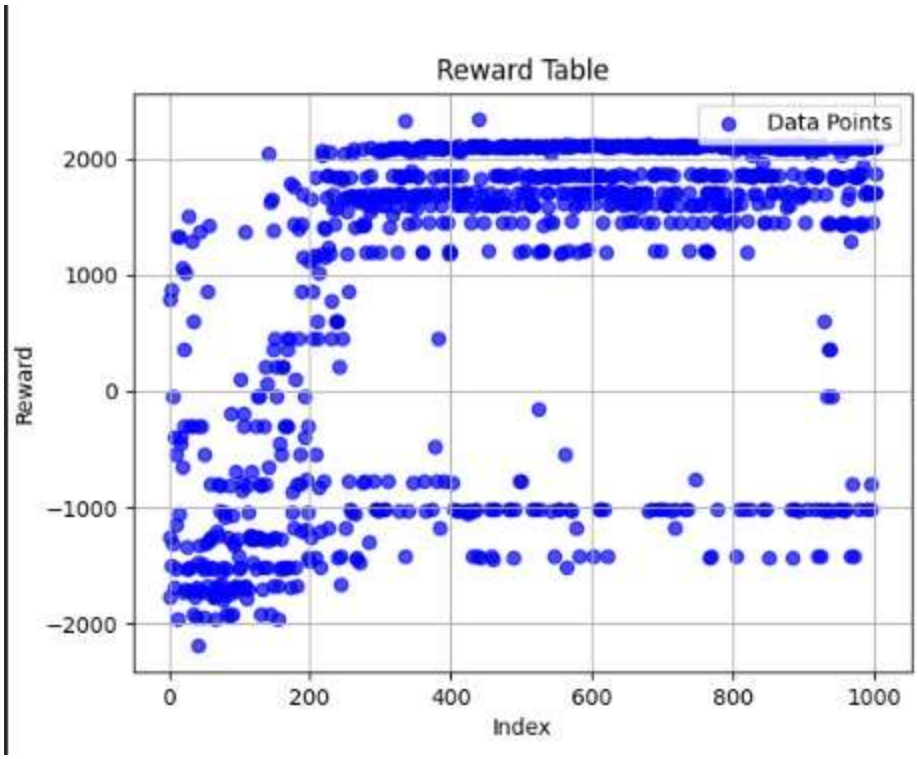
Reward Table
Data Points
Reward
Index
2000
1000
0
−1000
−2000
0
200
400
600
800
1000